«Всё, что можно мыслить, можно мыслить ясно.»

— Людвиг Витгенштейн

> Архив отвечает на запросы строками, а Машина превращает строку в допуск или отказ. Правила допуска дошли до экспедиции разными кусками, от списков шаблонов до пары строк грамматики.
>
> Часть шаблонов Машина разбирает, часть — нет, и разницу нужно знать заранее. Требования к запросам сменщики переписывали по памяти, и один набросок выдаёт желаемое за доказанное.

Задача 1: Классификация языков

База

Машина принимает запросы по шаблону. Не для каждого шаблона годится конечный автомат, и отличить одно от другого нужно до того, как шаблон попадёт в Машину.

1. L_1 — слова с чётным числом единиц. Постройте ДФА: выпишите состояния и переходы.
2. L_2 — слова, содержащие подслово «01». Постройте ДФА.
3. L_3 — слова вида $0^n 1^n$ при $n \geq 0$. Приведите аргумент нерегулярности.
4. L_4 — слова, в которых нет двух подряд идущих единиц. Постройте ДФА.
5. L_5 — слова, в которых единиц ровно на три больше, чем нулей. Приведите аргумент нерегулярности.

Задача 2: Регулярные выражения

База

Шаблон запроса удобно записать компактной формулой. Формула должна совпадать с шаблоном в точности, поэтому вхождения считаются по позициям, а не на глаз.

1. Запишите регулярное выражение над $\{0, 1\}$ для каждого языка:
   (а) слова с чётным числом единиц;
   (б) слова без двух подряд идущих нулей;
   (в) слова, в которых подслово «00» встречается ровно два раза, причём перекрывающиеся вхождения считаются: в слове «000» их два.

   Указание. *Считайте вхождения как позиции, где начинается «00», и разбейте слово на блоки нулей.*
2. Постройте ДФА по регулярному выражению $0^*(10^*)^*$, запишите словами язык, который оно задаёт, и подтвердите ответ на словах 1, 0110 и 11.

Задача 3: ДФА для делимости

База

Машина проверяет номера записей, а любое натуральное число записывается двоично. Куратору нужен автомат, который отличает запись числа, кратного трём.

> Автомат читает двоичную запись числа слева направо, старший разряд идёт первым. Пустая строка не является записью числа и отвергается, ведущие нули допустимы.

1. Постройте ДФА, распознающий двоичные записи чисел, делящихся на 3.

2. Опишите состояния и переходы и приведите инвариант: что означает состояние автомата после прочтения слова w?
3. Объясните, почему состояний не может быть меньше четырёх.
4. Проверьте автомат на числах $0, 3, 6, 9, 10$ (это $0_2, 11_2, 110_2, 1001_2, 1010_2$).

Задача 4: Подмножества и жадность — NFA в ДФА

Челлендж

Недетерминированный автомат короче записать, а исполнить всё равно придётся детерминированный. Экспедиция переводит один такой автомат в ДФА методом подмножеств.

> НКА N с состояниями $\{q_0, q_1, q_2\}$, алфавитом $\{0, 1\}$, начальным состоянием q_0 и допускающим q_2. Переходы: $\delta(q_0, 0) = \{q_0, q_1\}$, $\delta(q_0, 1) = \{q_0\}$, $\delta(q_1, 0) = \varnothing$, $\delta(q_1, 1) = \{q_2\}$, $\delta(q_2, 0) = \{q_2\}$, $\delta(q_2, 1) = \{q_2\}$.

1. Постройте детерминированный автомат методом подмножеств: выпишите все достижимые подмножества состояний и переходы между ними.
2. Запишите словами язык, который распознаёт N, и объясните, почему перевод сохраняет язык.
3. Объясните, почему число состояний ДФА может вырасти экспоненциально: сколько подмножеств у множества из n состояний? Для языка «третий символ с конца равен единице» постройте НКА и покажите, почему ДФА приходится помнить три последних символа.

Задача 5: Лемма о накачке

Челлендж

Нерегулярность языка доказывается леммой о накачке: в достаточно длинном слове находится цикл, который можно повторить.

> Лемма о накачке: если язык L регулярен, то найдётся такое p, что любое слово $w \in L$ длины не меньше p разбивается на части $w = xyz$ с условиями $|xy| \le p$, $|y| \ge 1$ и $xy^k z \in L$ при всех $k \ge 0$.

1. Докажите, что язык $L = \{a^n b^n \mid n \ge 0\}$ нерегулярен. Возьмите слово из L, зависящее от p, переберите возможные разбиения и укажите, при каком k слово выпадает из L.
2. Докажите, что язык палиндромов $\{w \mid w = w^R\}$ над $\{a, b\}$ нерегулярен.

Задача 6: Теорема Майхилла–Нероуда

Челлендж

Регулярность языка видна по тому, сколько у него классов неразличимых слов. Для двух слов это значит, что никакое продолжение не отличает одно от другого.

> Слова x и y неразличимы относительно языка L, если для любого слова z выполнено $xz \in L \leftrightarrow yz \in L$. Теорема Майхилла–Нероуда: язык регулярен тогда и только тогда, когда классов неразличимости конечное число, и это число равно числу состояний минимального ДФА.

1. Докажите, что язык $L = \{a^n b^n \mid n \ge 0\}$ нерегулярен: предъявите бесконечно много попарно различимых слов и для каждой пары укажите различающее продолжение z.

2. Для языка слов над $\{0, 1\}$, кратных 3 как двоичные числа, укажите число классов неразличимости и минимальный ДФА. Пустое слово не является записью числа и в язык не входит, ведущие нули допустимы.

Задача 7: Свойства замыкания

База

Куратор комбинирует шаблоны запросов и хочет знать, какие операции не выведут его за пределы регулярных языков.

1. Докажите замкнутость регулярных языков относительно объединения, дополнения, конкатенации и звезды Клини. В каждом случае опишите конструкцию автомата для результата.
2. Докажите замкнутость относительно пересечения через произведение автоматов: опишите состояния произведения и функцию переходов.
3. Верно ли, что разность регулярных языков регулярна? А симметрическая разность? Обоснуйте ответ через уже доказанные замыкания.
4. Дан регулярный язык L_1. Регулярен ли язык обращений слов из L_1? Докажите.

Задача 8: Минимизация ДФА

Челлендж

Один и тот же язык распознают многие автоматы, и куратору нужен самый экономный из них.

> ДФА с состояниями $A, \ldots, F$, алфавитом $\{0, 1\}$ и функцией перехода:
>
> | δ | **0** | **1** |
> |---|---|---|
> | A | B | A |
> | B | C | D |
> | C | E | F |
> | D | E | D |
> | E | A | D |
> | F | B | C |
>
> Состояние A — начальное и единственное допускающее, остальные состояния недопускающие. Состояния p и q различимы, если найдётся слово, по которому автомат из p и из q приходит в состояния разного типа.

1. Постройте таблицу различимости: начните с пар «допускающее и недопускающее» и продолжайте итеративно, пока не перестанут появляться новые пары. На каждом шаге указывайте, какая пара пополнила таблицу.
2. Найдите классы эквивалентности и постройте минимальный ДФА.
3. Совпадает ли минимальный ДФА с исходным? Ответ обоснуйте.

Задача 9: Контекстно-свободные грамматики

База

Вложенные скобки требуют памяти, которой у конечного автомата нет. Куратор расширяет средства описания запросов до контекстно-свободных грамматик.

> Контекстно-свободная грамматика задаётся переменными, терминалами, правилами и начальной переменной. Лемма о накачке для КС-языков: если язык контекстно-свободен, то найдётся такое p, что любое слово w длины не меньше p разбивается на части $w = uvxyz$ с условиями $|vxy| \le p$, $|vy| \ge 1$ и $uv^k xy^k z \in L$ при всех $k \ge 0$.

1. Постройте КС-грамматику для языка правильных скобочных последовательностей над $\Sigma = \{(,)\}$. Проверьте её на словах $()()$, $(())$ и $)($.
2. Объясните, почему язык $L = \{a^n b^n c^n \mid n \ge 0\}$ не является контекстно-свободным: примените лемму о накачке.
3. Для грамматики $S \to aSb \mid \varepsilon$ постройте дерево разбора слова aabb. Проведите его левосторонний вывод и сверьте последовательность правил с деревом.

Задача 10: Найди ошибку

Челлендж

В одном из набросков сменщика сохранилось доказательство регулярности языка.

> Рассмотрим язык L слов над $\{0, 1\}$, в которых число нулей равно числу единиц. Регулярное выражение $(01 \mid 10)^*$ порождает ровно слова с поровну нулей и единиц, значит L регулярен.

1. Где ошибка? Выпишите два-три слова из L, которые не порождаются $(01 \mid 10)^*$, и объясните, что на самом деле задаёт это выражение.
2. Докажите, что $(01 \mid 10)^*$ порождает только слова, разбивающиеся на пары «01» или «10».
3. Докажите нерегулярность L: леммой о накачке, неразличимостью по Майхиллу–Нероуду или автоматным рассуждением.

Необязательные бонусные задачи

> Бонусные задачи не входят в обязательный минимум. Они заметно сложнее основных и требуют либо программирования, либо самостоятельного обобщения материала. Оценивается в них прежде всего объяснение модели, её корректности и границ применимости.

Задача A: От регулярного выражения к минимальному автомату

Бонус

Куратору нужно проверять запросы по шаблону и знать, насколько компактен автомат, который этот шаблон задаёт.

1. Сопоставьте слово с выражением через производные Бржозовского: производная выражения по символу — выражение для «хвоста» языка, и слово принадлежит языку, когда после всех символов осталось выражение с ε. Правила: $D_a(a) = \varepsilon$, $D_a(b) = \emptyset$ при $b \neq a$, $D_a(\varepsilon) = \emptyset$, $D_a(R \mid S) = D_a(R) \mid D_a(S)$, $D_a(RS) = D_a(R)S$ плюс $D_a(S)$, если R выводит ε, $D_a(R^*) = D_a(R)R^*$.
2. Поддержите операторы: конкатенация, альтернатива $|$, звёздочка $*$, плюс, символы, точка.
3. Реализуйте `match(re, s)`: проверка, входит ли строка `s` в язык `re` (полное совпадение).
4. Постройте минимальный ДФА без разбиения состояний: обратите переходы, детерминизируйте, снова обратите и снова детерминизируйте (минимизация Бржозовского). Сверьте число состояний минимального ДФА с числом классов неразличимости того же языка.
5. Напишите тесты `a*`, `a|b`, `(ab)*c`, `a*b*`: для каждого проверьте матчинг и размер минимального ДФА.
6. Сравните число состояний после первой детерминизации обращённого автомата и после второй. Подберите три выражения, на которых первая даёт больше состояний, и заполните таблицу: выражение, размер после первой, после второй, во сколько раз. Объясните, какие состояния склеиваются на втором шаге.

Задача B: Минимизация ДФА

Бонус

Куратор хочет автоматически находить самый компактный автомат для языка, а не выписывать таблицу различимости вручную.

1. Реализуйте алгоритм минимизации ДФА (Хопкрофт или разбиение Мура).
2. Минимизируйте ДФА из задачи 8 и сверьте результат с ручным решением.
3. Реализуйте также проверку эквивалентности двух ДФА (через произведение автоматов).
4. Реализуйте второй алгоритм и сравните Хопкрофта с Муром на случайных ДФА с 10, 100 и 1000 состояниями. Как время зависит от числа классов эквивалентности и почему?

Задача C: CYK — проверка принадлежности

Бонус

Куратору нужно динамическим программированием проверять, выводится ли запрос из грамматики.

1. Реализуйте алгоритм Кока–Янгера–Касами (CYK) для проверки принадлежности слова контекстно-свободной грамматике в нормальной форме Хомского (НФХ).
2. Проверьте слово «aabb» по грамматике $S \to AB$, $A \to aA \mid a$, $B \to bB \mid b$ (представьте её в НФХ).
3. Добавьте построение дерева разбора.
4. Придумайте неоднозначную грамматику в НФХ и слово, у которого есть два разных дерева разбора. Покажите оба дерева и объясните, почему по одной таблице CYK можно восстановить оба, хотя в каждой клетке стоит только множество нетерминалов.