

Дискретная математика

Абстрактная интерпретация

Константин Чухарев

Осень 2026

Абстрактная интерпретация

| *Все модели неверны, но некоторые полезны.*

— Джордж Бокс

Почему тестов недостаточно

Программа, делящая на введённое число, прошла тесты на входах $x = 5$, $x = -2$, $x = 7$. Все три запуска успешны — и всё равно ничего не доказано. На четвёртом входе, $x = 0$, программа упадёт с ошибкой деления на ноль. Тестирование показывает наличие ошибок, но никогда не доказывает их отсутствия: ошибка может прятаться на любом следующем входе.

Перебрать все входы невозможно. Вход — 64-битное целое: возможных значений 2^{64} , больше, чем секунд в возрасте Вселенной. Для программы, читающей список чисел, входов бесконечно много.

Доказывать свойство нужно для всех запусков сразу, не выполняя программу ни на одном из них.

Аппроксимация вместо точного ответа

Точный автоматический ответ недостижим: свойства произвольной программы неразрешимы. Остаётся приближённый ответ — и его оказывается достаточно. Точный ответ «да» или «нет» гарантировать нельзя. Достаточно разрешить третий ответ, «не знаю», и задача перестаёт быть безнадёжной.

Простейший корректный анализ отвечает «не знаю» на любой вопрос: он не ошибается, но и не сообщает ничего полезного. Вся дальнейшая работа — ужимать этот «не знаю» до точного ответа там, где это возможно.

Аппарат для приближённого ответа уже знаком: знаковая решётка, супремум и неподвижная точка. Вместо точных значений анализ работает с их грубыми обобщениями — *абстракциями*. Цена — неточность: анализ может сообщить о возможной ошибке там, где на деле всё в порядке. Корректность при этом сохраняется: ни одна реальная ошибка не пропадает.

Знаки вместо чисел

Идея проста: заменить точные значения их грубыми обобщениями. Чтобы доказать, что знаменатель не равен нулю, достаточно знать, что x не бывает нулём. Вместо числа возьмём его *знак*: положительное, отрицательное или ноль. Добавим два особых значения — «неизвестно» и «недостижимо». Таких обобщений конечное число, и программа «выполняется» на них за конечное число шагов.

Пример


Для доказательства отсутствия деления на ноль в программе $y := 10 / x$ достаточно знать знак x . Домен знаков различает случаи: при $x \neq 0$ деление на ноль невозможно. При $x = 0$ — возможно.

Домен знаков

Определение 1 (Домен знаков)

Домен знаков состоит из пяти элементов:

- $\top$ — «знак неизвестен» (значение может быть любым),
- $+$ — «значение положительно»,
- 0 — «значение равно нулю»,
- $-$ — «значение отрицательно»,
- $\perp$ — «значение невозможно» (переменная здесь не определена).



Элементы упорядочены по точности: $\perp$ — самое точное (значения нет), $\top$ — самое грубое (значение любое). Нагляднее всего порядок виден на решётке: $\perp \preceq \{-, 0, +\} \preceq \top$.

Информационный порядок

Определение 2 (Информационный порядок)

Говорим, что $a \preceq b$ (« a не грубее b »), если любой конкретный смысл a содержится в конкретном смысле b . Например, $+$ $\preceq$ $\top$: «положительное» точнее, чем «любое». И $\perp \preceq +$: «недостижимо» точнее, чем «положительное».

Почему порядок «наоборот»

Абстракция и конкретизация

Каждое абстрактное значение описывает множество конкретных значений. Значение $+$ описывает все положительные числа, $\top$ — все целые, 0 — только ноль.

Определение 3 (Конкретизация)

Пусть $\mathcal{C}$ — множество конкретных состояний программы, а D — абстрактный домен.

Конкретизация $\gamma : D \rightarrow \mathcal{P}(\mathcal{C})$ отображает абстрактное значение в множество конкретных состояний, которые оно представляет.

Определение 4 (Абстракция)

Абстракция $\alpha : \mathcal{P}(\mathcal{C}) \rightarrow D$ отображает множество конкретных состояний в наиболее точное абстрактное значение, его покрывающее:

$$\alpha(X) = \sqcap \{d \in D \mid X \subseteq \gamma(d)\}.$$

Для домена знаков $\alpha(\{5, 7\}) = +$. Конкретизация: $\gamma(+) = \{x \in \mathbb{Z} \mid x > 0\}$.

Связка Галуа

Связка Галуа

Абстрактный домен

Определение 5 (Абстрактный домен)

Абстрактный домен — решётка $(D, \preceq, \perp, \top, \sqcup, \sqcap)$, где:

- $\preceq$ — информационный порядок («не грубее»),
- $\perp$ — наименьший элемент («недостижимо»),
- $\top$ — наибольший элемент (все значения),
- $\sqcup$ — объединение: $a \sqcup b$ описывает всё, что описывают a и b ,
- $\sqcap$ — пересечение: $a \sqcap b$ — наиболее точное значение, совместимое с обоими.

Объединение соответствует слиянию веток программы, пересечение — усилению требования.

Абстрактные состояния

Для программы с n переменными абстрактное состояние — вектор из n абстрактных значений. Например, $(-, +, 0, \dots)$. Порядок поэлементный: $a \preceq b \Leftrightarrow \forall i. a_i \preceq b_i$. Конечный текст программы описывается конечным множеством абстрактных состояний.

Переносящие функции

Конкретная семантика оператора превращает множество состояний в множество состояний. Например, оператор $x := x + 1$ переводит множество значений в сдвинутое множество. То есть $X + 1 = \{v + 1 \mid v \in X\}$.

Определение 6 (Переносящая функция)

Переносящая функция — отображение $\llbracket s \rrbracket^\# : D \rightarrow D$, которое вычисляет абстрактное состояние после оператора s по абстрактному состоянию до оператора.
Интуиция: «запустить оператор на абстрактных значениях».

Пример: присваивание в домене знаков

Пример (Присваивание в домене знаков)

Пусть $x := x + 1$. Абстрактный результат:

- $+$ $\rightarrow$ $+$ — положительное плюс единица остаётся положительным;
- $-$ $\rightarrow$ $\top$ — отрицательное плюс единица может стать нулём;
- 0 $\rightarrow$ $+$;
- $\top$ $\rightarrow$ $\top$;
- $\perp$ $\rightarrow$ $\perp$.

Правило $- \rightarrow \top$ — цена абстракции: знак не различает -1 и -5 . Он не видит, что $-1 + 1 = 0$.

Корректность переноса

Переносящая функция обязана быть *корректной*: она не имеет права терять ни одно реальное поведение.

Определение 7 (Корректность переноса)

Переносящая функция $\llbracket s \rrbracket^\sharp$ *корректна*, если для любого абстрактного состояния d

$$\llbracket s \rrbracket(\gamma(d)) \subseteq \gamma(\llbracket s \rrbracket^\sharp(d)),$$

где $\llbracket s \rrbracket$ — конкретная семантика оператора s на множествах состояний. Перенос добавляет лишь невозможные поведения и не теряет настоящие.

Определение 8 (Монотонность)

Перенос $\llbracket s \rrbracket^\sharp$ *монотонен*, если из $d_1 \preceq d_2$ следует $\llbracket s \rrbracket^\sharp(d_1) \preceq \llbracket s \rrbracket^\sharp(d_2)$. Без монотонности итерации по циклу могут не сходиться.

Сложение в домене знаков

Пример (Сложение в домене знаков)

Операция $z := x + y$ требует абстрактной таблицы сложения знаков. Правила:

- $+\boxplus+ = +$;
- $-\boxplus- = -$;
- $x \boxplus 0 = x$ для любого знака x ;
- $+\boxplus- = \top$ — сумма знаков может быть любой;
- $\top \boxplus x = \top$ при $x \neq \perp$;
- $\perp \boxplus x = \perp$.

Правило $+\boxplus- = \top$ — источник неточности: знак не хранит величин. Он не видит, что $7 + (-4) = 3 > 0$. Корректность сохраняется: абстрактный результат $\top$ покрывает реальный.

Интервальный домен

Программа суммирует элементы массива:

```
s := 0
for i in 0..n do
  s := s + a[i]
```

Индекс i не должен выйти за границы массива. Чтобы доказать это, достаточно знать, что i лежит в отрезке $[0, n - 1]$.

Определение 9 (Интервальный домен)

Абстрактное значение — интервал $[l, h]$ либо особый элемент $\perp$. Здесь $l, h \in \mathbb{Z} \cup \{-\infty, +\infty\}$. Конкретизация — все целые числа из интервала $[l, h]$. $\top = [-\infty, +\infty]$. Порядок по включению: $[a, b] \preceq [c, d] \Leftrightarrow [a, b] \subseteq [c, d]$. Объединение — выпуклая оболочка: $[a, b] \sqcup [c, d] = [\min(a, c), \max(b, d)]$. Пересечение — наиболее точный интервал: $[\max(a, c), \min(b, d)]$ (пусто, если нижняя граница больше верхней).

Интервалы и связи между переменными

Сложение интервалов поэлементное: $[a, b] + [c, d] = [a + c, b + d]$.

Интервальный домен теряет связи между переменными. Если в каждой точке программы $y = x - 1$, точное множество пар лежит на прямой. Интервальный анализ видит лишь прямоугольник $x \in [2, 5], y \in [1, 4]$ и не замечает, что y определён значением x . Связи между переменными возвращают более богатые домены — октагоны и полиэдры.

Пример (Выход за границы массива)

Пусть в программе $i \in [0, 9]$, а массив имеет 10 элементов. Перенос обращения к элементу $A[i]$ проверяет, что индекс в границах. Если интервал i выходит за границы — например, $[0, 10]$ — анализатор сообщает о возможном выходе за границы. Сообщение может оказаться ложным, а реальный выход за границы он не пропустит.

Домен констант

Определение 10 (Домен констант)

Абстрактное значение — либо конкретное целое c , либо особое значение $\top$ («не константа»), либо $\perp$ («недостижимо»). Порядок: $\perp \preceq c \preceq \top$ для всех целых c .

Домен констант доказывает равенства. После присваиваний $x := 3, y := x + 4$ выполняется равенство

$$y = 7.$$

Компиляторы используют его для *распространения констант*: подставить вычисленное значение и упростить выражение.

Пример: распространение констант

Пример (Распространение констант)

Программа:

```
x := 3  
y := x + 4  
z := y * 2
```

Анализ констант: $x = 3, y = 7, z = 14$. Компилятор заменит $z := y \cdot 2 \rightarrow z := 14$.

Перенос условий

Определение 11 (Перенос условий)

Условие переносится как *фильтр*: абстрактное состояние пересекается с множеством, заданным условием. Например, для условия $i < n$ интервал i в ветке «да» становится $[l, h] \rightarrow [l, \min(h, n - 1)]$ (при известной константе n). Если $l > n - 1$ — ветка «да» недостижима. Ветка «нет» получает пересечение с дополнением: $[l, h] \sqcap [n, +\infty]$. Если n неизвестна (её интервал — $\top$), фильтр ничего не отсекает.

Неподвижная точка цикла

Простая последовательность операторов переносится естественно: идём по программе, применяя переносящие функции. С условными операторами объединяем ветки через $\sqcup$. Сложность — циклы: тело цикла может выполняться сколько угодно раз.

Пусть E — состояние в голове цикла при входе. Определим $F(d) = E \sqcup \llbracket B \rrbracket^\sharp(d)$: объединение состояния на входе и результата одного прохода тела из d . Состояние после любого числа проходов — наименьшая неподвижная точка F :

$$\text{lfp}(F) = \sqcup_{k \geq 0} F^k(\perp).$$

Смысл: последовательность $F^k(\perp)$ монотонно накапливает состояния, достижимые в голове цикла. Объединив все $F^k(\perp)$, получаем состояние после любого числа проходов.

Итерация Клини

Теорема 1 (Итерация Клини)

Если F монотонна и домен конечен, последовательность итераций $d_0 = \perp, d_{k+1} = F(d_k)$ достигает $\text{lfp}(F)$ за конечное число шагов.

Доказательство (Доказательство)

Монотонность даёт $d_0 \preceq d_1 \preceq d_2 \preceq \dots$: последовательность не убывает. В конечной решётке любая неубывающая последовательность стабилизируется. С какого-то момента $d_{k+1} = d_k$. Тогда $F(d_k) = d_k$ — неподвижная точка. Она наименьшая: любая неподвижная точка содержит $\perp = d_0$. Значит, она содержит и все последующие d_k .

Расходящаяся итерация

Домен знаков конечен — циклы в нём анализируются перебором. Интервальный домен бесконечен: интервалы вида $[0, n]$ с ростом n никогда не стабилизируются. Именно здесь наивная итерация ломается.

Пример (Расходящаяся итерация)

Рассмотрим цикл

```
i := 0
while i < n do
  i := i + 1
```

Интервальный анализ состояния i в голове цикла даёт последовательность $[0, 0], [0, 1], [0, 2], [0, 3], \dots$. Каждая итерация расширяет интервал на единицу. Процесс никогда не остановится: наивной итерацией неподвижную точку не получить.

Расходящаяся итерация [2]

Условие $i < n$ здесь не помогает: значение n неизвестно (его интервал — $\top$), поэтому фильтр условия ничего не отсекает.

Widening

Определение 12 (Оператор расширения)

Бинарная операция $\nabla : D \times D \rightarrow D$, для которой:

- $a \sqcup b \preceq a \nabla b$ (результат не менее груб, чем объединение),
- для любой возрастающей последовательности $d_0 \preceq d_1 \preceq \dots$ последовательность $w_0 = d_0, w_{k+1} = w_k \nabla d_{k+1}$ стабилизируется за конечное число шагов.

Словами: оператор ∇ «ускоряет» рост, сбрасывая нестабильные компоненты в $\top$.

Widening для интервалов

Пример (Widening для интервалов)

Классический widening:

$$[l_1, h_1] \nabla [l_2, h_2] = [l, h],$$

$$l = \begin{cases} -\infty & \text{если } l_2 < l_1, \\ l_1 & \text{иначе} \end{cases},$$

$$h = \begin{cases} +\infty & \text{если } h_2 > h_1. \\ h_1 & \text{иначе} \end{cases}.$$

В примере со счётчиком $[0, 0] \nabla [0, 1] = [0, +\infty]$: верхняя граница выросла — сбрасываем её в бесконечность. Следующая итерация: $[0, +\infty] \nabla [0, +\infty] = [0, +\infty]$ — стабилизация. Неподвижная точка достигнута за два шага.

Narrowing

Определение 13 (Оператор сужения)

Бинарная операция $\triangle : D \times D \rightarrow D$. Результат не грубее первого операнда: $a \triangle b \preceq a$. Повторяя сужение из уже достигнутой неподвижной точки, получаем более точную неподвижную точку.

Пример (Narrowing в примере со счётчиком)

Сужение идёт по условию цикла. При известной константе n фильтр $i < n$ уточняет интервал $[0, +\infty] \rightarrow [0, n - 1]$. Верхняя граница восстановлена из условия.

Схема «widening для сходимости, narrowing для точности» — стандартный рецепт анализа циклов в интервальном домене.

Цена аппроксимации

Абстрактный анализ корректен, но не точен. Корректность здесь означает: анализатор не пропускает реальные ошибки. Неточность означает: он может сообщить об ошибке, которой на деле нет.

Определение 14 (Ложное срабатывание)

Если анализатор сообщает о возможной ошибке в точке, где ошибки не бывает, — это *ложное срабатывание* (false positive). Корректный анализатор допускает ложные срабатывания, но не допускает пропусков.

Абстракция рисует вокруг исполнений оболочку. Если оболочка не задевает «запретную» область, ошибка доказанно невозможна. Если задевает — анализатор не различает реальную ошибку и ложную тревогу. Замалчивание в неоднозначном случае было бы пропущенной реальной ошибкой.

Пример: точность и домен

Пример (Точность и домен)

Рассмотрим программу $x := 6, y := -7, z := x + y$. Домен знаков даёт для неё $z = \top$: знак суммы не вычисляется. В действительности $z = -1$ — определённое число. Домен констант посчитал бы $z = -1$ точно. Домен интервалов — $[-1, -1]$. Выбор домена — компромисс между точностью, стоимостью и свойством, которое нужно доказать.

Применения

Абстрактная интерпретация — основа индустрии статического анализа.

- Оптимизирующие компиляторы (GCC, LLVM) внутри — анализаторы потоков данных: распространение констант, анализ диапазонов, удаление мёртвого кода.
- Astrée доказала отсутствие ошибок времени выполнения в полётном софте Airbus A340 и A380.
- Polyspace (MathWorks) верифицирует встраиваемый софт.
- Frama-C — открытая платформа анализа кода на C.

Абстрактная интерпретация вычисляет инварианты циклов автоматически. Человеку их придумывать не нужно.

Символьное исполнение

Символьное исполнение — противоположный полюс: оно перебирает пути точно, ценой стоимости. На практике подходы работают вместе: анализ находит подозрительные места, символьное исполнение подтверждает их по конкретным путям.

Что мы поняли?

- Тестирование не доказывает отсутствие ошибок: свойство нужно доказывать для всех запусков сразу.
- Точный анализ программ неразрешим — работает корректная аппроксимация с третьим ответом «не знаю».
- Абстрактный домен — решётка с информационным порядком; связь с конкретным задают α и γ .
- Переносящие функции переносят операторы в абстрактный мир и обязаны быть корректными и монотонными.
- Знаки, интервалы и константы — домены для разных свойств.
- Неподвижная точка переносящей функции цикла — результат анализа; widening и narrowing обеспечивают сходимость.
- Ложные срабатывания неизбежны, пропуски ошибок — нет.

Вопросы для самопроверки

- Почему тестирование не может доказать отсутствие ошибок?
- Что такое абстрактный домен, и зачем нужны $\perp$ и $\top$?
- Как связаны абстракция α и конкретизация γ ?
- Почему $+ \boxplus - = \top$ в домене знаков?
- Чем интервальный домен отличается от знакового?
- Почему наивная итерация для интервалов расходится, и как widening это исправляет?
- Почему ложные срабатывания неизбежны, а пропуски ошибок — нет?