5

Лекция 9–10 марта

Детерминированные автоматы

Константин Чухарев

Дискретная математика — Весна 2027

Языки и слова

> *Язык есть орган, образующий мысль.*
>
> ***— Вильгельм фон Гумбольдт***

Что читает машина?

Программа всегда читает строку.

Число записано цифрами, граф — перечнем рёбер, программа — текстом.

Всё, что машина читает, — строка.

Пример

- редактор вылавливает из документа строку +7 999 123-45-67
- компилятор режет строку if x > 0 на ключевые слова и числа
- протокол связи проверяет, корректна ли строка GET /index HTTP/1.1

Во всех трёх задачах решение выносится по строке, которую машина читает слева направо.

Алфавит, слово, язык

Всё, что читает машина, собрано из символов. Дадим этим объектам имена.

Определение 1

- **Алфавит** — конечное множество символов Σ.
- **Слово** — конечная последовательность символов алфавита. Длина слова w обозначается $|w|$. **Пустое слово** ε — единственное слово длины 0.
- **Язык** — произвольное множество слов $L \subseteq \Sigma^*$.

Пример

Над алфавитом $\{0, 1\}$ слово 1001 имеет длину 4, пустое слово ε — длину 0.

Язык слов, заканчивающихся на 01, содержит 101 и 1001, но не 10 и не 1000.

Распознать язык — уметь для любого слова ответить, лежит ли оно в нём.

Пустое слово и пустой язык

Три множества слов легко перепутать.

Язык	Что содержит
$\varnothing$	ни одного слова
$\{\varepsilon\}$	одно слово длины 0
Σ^*	все слова алфавита

Язык $\{\varepsilon\}$ и язык $\varnothing$ различны. В первом есть слово, во втором слов нет вовсе.

Пустое слово — полноценный элемент языка, как ноль — полноценное число.

Сколько слов над алфавитом?

Хотя слов бесконечно много, в каждой длине их конечное число.

Теорема 1 (Подсчёт слов)

Если $|\Sigma| = k$, то слов длины ровно n — ровно k^n.

Доказательство

Слово длины n — это n независимых позиций по k вариантов. Выборы перемножаются и дают k^n, а разные наборы дают разные слова.

Пример

Двоичный алфавит, слова длины не больше 2 — это ε, 0, 1, 00, 01, 10, 11.

Итого $1 + 2 + 4 = 7$ — слова разных длин не пересекаются, поэтому количества складываются.

Все ли языки можно описать?

Автоматы и формулы описывают языки, но хватит ли их на все? Посчитаем языки и сравним с числом описаний.

Теорема 2 (Подсчёт языков)

Над непустым алфавитом языков ровно $2^{\aleph_0}$ — континуум.

Доказательство

Докажем кодированием языков битовыми последовательностями.

Слова перечисляются по длинам, поэтому Σ^* счётно. Язык задаётся последовательностью битов, где единица стоит на слове из L, а ноль на остальных. Разные языки дают разные последовательности. Обратное тоже верно, поэтому соответствие однозначно.

Множество всех подмножеств счётного множества имеет мощность $2^{\aleph_0}$ — континуум.

Язык как последовательность битов

Упорядоченные слова образуют бесконечную строку клеток. У каждого слова своя клетка, а язык — расстановка единиц в ней.

Пример

Над алфавитом $\{0, 1\}$ упорядочим слова по длинам. Сначала идёт ε, затем 0, 1, затем слова длины 2 и так далее.

Язык слов, заканчивающихся на 01, получает последовательность $0, 0, 0, 0, 1, \ldots$. Первая единица стоит напротив слова 01.

Сама последовательность — не запись языка. Она бесконечна. Конечные записи — машина или формула — задают лишь малую долю языков.

Операции над языками

К операциям множеств добавляется склейка слов.

Определение 2

- **Конкатенация** — $L_1 L_2 = \{uv \mid u \in L_1, v \in L_2\}$.
- **Степень** — $L^0 = \{\varepsilon\}$, $L^{n+1} = L^n L$.
- **Звезда Клини** — $L^* = \bigcup_{n \geq 0} L^n$, ноль и более повторений.

Пример

$\{\mathrm{a}, \mathrm{ab}\} \cdot \{\mathrm{c}\} = \{\mathrm{ac}, \mathrm{abc}\}$ — левый язык приписан к правому во всех комбинациях.

$\{0, 1\}^2 = \{00, 01, 10, 11\}$ — все слова длины 2.

$\{\mathrm{a}\}^*$ собирает a, aa, aaa и так далее, плюс пустое слово из L^0.

Звезда Клини — сжатая запись повторения одного и того же куска.

Алгебра языков

Языки — множества, поэтому над ними работают все операции множеств.

$$L_1 \cup L_2, \quad L_1 \cap L_2, \quad \overline{L} = \Sigma^* \setminus L.$$

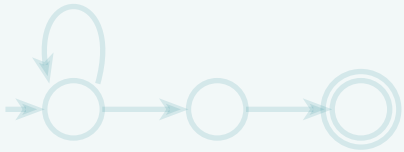
Законы де Моргана из логики высказываний переносятся на языки дословно.

$$\overline{L_1 \cup L_2} = \overline{L_1} \cap \overline{L_2}.$$

Проверим на языках слов, кончающихся на 0 и на 1. Их объединение — все непустые слова, поэтому дополнение объединения содержит только ε. Пересечение дополнений даёт то же самое.

Языки замкнуты относительно объединения, пересечения и дополнения, потому что это множества.

Новая операция здесь одна, и это конкатенация. У числовых множеств такой операции нет.



Детерминированные автоматы

> *Только разнообразие может поглотить разнообразие.*
>
> ***— Уильям Росс Эшби***

Три гипотезы о конце слова

Хотим автомат для языка слов, заканчивающихся на 01.

Что нужно помнить о прочитанном префиксе?

Память не может расти вместе со словом. В ней должны жить только гипотезы, важные для конца.

- Конец не зависит от префикса, если он пуст или кончается на 1 — состояние q_0.
- Последний символ 0 может оказаться предпоследним — состояние q_1.
- Последние два символа 01 дают принимающее состояние q_2.

> Гипотезы о будущем превращаются в состояния автомата.
>
> Переход — это обновление гипотезы при чтении очередного символа.

Детерминированный конечный автомат

Каждая гипотеза становится состоянием, а обновление — переходом.

Определение 3 (ДКА)

Детерминированный конечный автомат задаётся пятёркой $M = (Q, \Sigma, \delta, q_0, F)$.

- Q — конечное множество состояний.
- Σ — алфавит.
- $\delta : Q \times \Sigma \to Q$ — всюду определённая функция переходов.
- $q_0 \in Q$ — начальное состояние.
- $F \subseteq Q$ — принимающие состояния.

Состояние — вся память автомата, сжатая история префикса.

Детерминированность — отсутствие выбора, по паре (состояние, символ) следующее состояние одно.

Автомат как размеченный орграф

У автомата есть графовая внешность.

В автомате	В орграфе
состояния	вершины
переходы	дуги
метки переходов	подписи дуг
начальное состояние	выделенная вершина
принимающие состояния	выделенное подмножество вершин

Вычисление — путь из выделенной вершины, метки пути складываются в слово.

Язык автомата — метки путей, кончающихся в принимающих вершинах.

Это обычный орграф, поэтому к нему применимы достижимость, циклы и обходы.

Чётное число единиц

Состояние	по 0	по 1
q_0 — принимающее	q_0	q_1
q_1	q_1	q_0

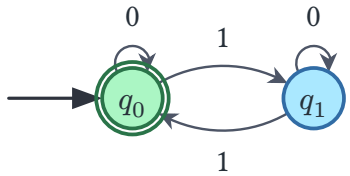


Таблица и есть функция переходов. Ноль состояние не меняет, единица переключает. Каждый символ слова — один шаг по таблице. На диаграмме стрелка из ниоткуда — старт, двойная обводка — принимающее состояние.

Пример

Прогон слова 011 даёт $q_0 \to q_0 \to q_1 \to q_0$, и слово принимается.

Прогон слова 01 даёт $q_0 \to q_0 \to q_1$, и слово отвергается.

Пустое слово принимается, потому что ноль единиц — чётное число.

Расширенная функция переходов

Один вызов δ сдвигает автомат на один символ.

Определение 4 (Расширенная функция переходов)

Расширенная функция переходов $\hat{\delta} : Q \times \Sigma^* \to Q$ протягивает δ на целые слова.

- **Базис** — $\hat{\delta}(q, \varepsilon) = q$.
- **Шаг** — $\hat{\delta}(q, aw) = \hat{\delta}(\delta(q, a), w)$.

Пример

$$\begin{aligned}\hat{\delta}(q_0, 011) &= \hat{\delta}(\delta(q_0, 0), 11) = \hat{\delta}(q_0, 11) \\ &= \hat{\delta}(\delta(q_0, 1), 1) = \hat{\delta}(q_1, 1) \\ &= \hat{\delta}(\delta(q_1, 1), \varepsilon) = \hat{\delta}(q_0, \varepsilon) = q_0.\end{aligned}$$

В автомате чётности q_0 принимающее, поэтому слово 011 лежит в языке.

Язык автомата

Соберём слова, которые заканчивают прогон в принимающем состоянии.

Определение 5

Язык автомата M задаётся формулой.

$$L(M) = \left\{ w \in \Sigma^* \;\middle|\; \hat{\delta}(q_0, w) \in F \right\}.$$

Язык называется **регулярным**, если он распознаётся некоторым ДКА.

Пример

В автомате чётности слова ε и 011 содержат чётное число единиц, поэтому оба лежат в $L(M)$, а 1 нечётно и в $L(M)$ не лежит.

Два автомата эквивалентны, если распознают один и тот же язык.

Автомат в программе

Таблица переходов ложится в двумерный массив. Строки массива занумерованы состояниями, столбцы — символами алфавита.

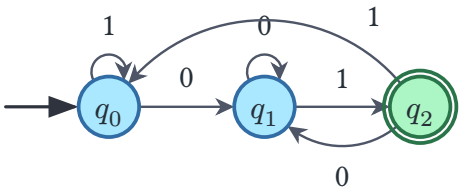
Принятие слова — цикл по символам, один шаг — один табличный переход.

```
let mut q = start;
for &sym in word {
    q = trans[q][sym];
}
accept[q]
```

Массив `trans` хранит таблицу δ.

Каждый символ обрабатывается за $O(1)$, и такой цикл — простейшая реализация **конечного автомата**.

Слова, заканчивающиеся на «01»



Пример

Прогон слова 1001 идёт по дугам $q_0 \to q_0 \to q_1 \to q_1 \to q_2$. Последнее состояние принимающее, поэтому слово лежит в языке.

Прогон слова 1000 кончается в q_1 и отвергается.

Слово 010 тоже отвергается, хотя содержит 01. После первых двух символов автомат стоял в q_2, но последний ноль увёл его обратно в q_1.

Первый и последний символ

Язык — слова, у которых первый символ совпадает с последним.

Состояние $q_{a,b}$ помнит, каким символом слово началось и каким кончилось. Стартовое состояние q_0 обслуживает случай «символов ещё нет».

Состояние	по 0	по 1
q_0	$q_{0,0}$	$q_{1,1}$
$q_{0,0}$ — принимающее	$q_{0,0}$	$q_{0,1}$
$q_{0,1}$	$q_{0,0}$	$q_{0,1}$
$q_{1,0}$	$q_{1,0}$	$q_{1,1}$
$q_{1,1}$ — принимающее	$q_{1,0}$	$q_{1,1}$

Пример

- Прогон слова 0110 даёт $q_0 \to q_{0,0} \to q_{0,1} \to q_{0,1} \to q_{0,0}$, и слово принимается.
- Прогон слова 100 даёт $q_0 \to q_{1,1} \to q_{1,0} \to q_{1,0}$, и слово отвергается, потому что слово началось единицей, а кончилось нулём.

Что у автомата в памяти?

Состояние — сжатая история префикса.

Оно хранит класс префиксов, которые ведут себя одинаково на любом продолжении.

- Язык «заканчивается на 01» распознаётся тремя состояниями, ведь важно лишь, кончается ли префикс на 0, на 01 или ни на то, ни на другое.
- Язык «чётное число единиц» распознаётся двумя состояниями, и достаточно помнить чётность.
- Язык «в слове поровну нулей и единиц» заставляет помнить разность, а она не ограничена.

> Конечность памяти — граница модели.
>
> Язык $0^n 1^n$ в неё не помещается.

Итоги автоматов

Конечная таблица переходов задаёт автомат, а автоматы распознают регулярные языки.

- Всё, что читает машина, — строка. Алфавит — набор символов, слово — одна строка, язык — множество строк $L \subseteq \Sigma^*$.
- ДКА — пятёрка $(Q, \Sigma, \delta, q_0, F)$, вся память — номер состояния. Состояние — сжатая история префикса, детерминизм — отсутствие выбора.
- Язык автомата собирается расширенной функцией $\hat{\delta}$ и условием $\hat{\delta}(q_0, w) \in F$.
- Автомат — размеченный орграф, и распознавание идёт путём от выделенной вершины в принимающую.

Вопросы по автоматам

языки и автоматы

1. Над алфавитом $\{0, 1\}$ сколько слов длины 3? А длины не больше 3?
2. Постройте ДКА для языка слов над $\{0, 1\}$, содержащих подстроку 10.
3. Почему $\varnothing$ и $\{\varepsilon\}$ — разные языки? Какой из них распознаёт ДКА с недостижимым принимающим состоянием?
4. Слово ab длины 2 переводит автомат из q_0 в q_2. Выпишите шаги разложения $\hat{\delta}(q_0, \mathrm{ab})$ по определению.

Что почитать?

Задача	Где читать
Понять языки	m23, раздел «Алфавит, слова и формальные языки»
Построить DFA	m23, раздел «Детерминированные конечные автоматы»
Читать дальше	m23, разделы «Недетерминированные конечные автоматы» и «Регулярные выражения»