


Лекция

30–31 марта

Минимизация автоматов



Различимость состояний

Что значит имя? Роза пахнет розой, хоть розой назови её, хоть нет.

— Уильям Шекспир

Зачем минимизировать?

Таблица переходов — память автомата в железе и в коде.

Лишние состояния — лишние строки таблицы, лишние проверки, лишние регистры.

Пример

Один и тот же язык «чётное число единиц» распознают автомат из двух состояний и автомат из четырёх.

Второй работает, но треть его состояний — балласт.

Вопрос имеет два этажа: как найти лишние состояния и почему после чистки не осталось ещё одно лишнее.

Ответы — алгоритм таблицы различимостей и теорема о единственности.

Эквивалентность состояний

Определение 1

Состояния p, q **эквивалентны**, если на любом слове w оба принимают или оба отвергают:

$$\hat{\delta}(p, w) \in F \Leftrightarrow \hat{\delta}(q, w) \in F.$$


Иначе состояния **различимы**: есть слово-свидетель w , разводящее их ответы.

Пример

Свидетель может быть коротким: слово 1 различает q_0 и q_1 автомата чётности — из q_0 слово 1 отвергается, из q_1 принимается.

Эквивалентные состояния — одно состояние под двумя именами, их склейка и есть минимизация.

Четыре состояния вместо двух



Пример


Автомат распознаёт чётность единиц, но переход по 0 из r_0 уводит в r_2 , а из r_1 — в r_1 .

Четыре состояния вместо двух [2]

Пары r_0, r_2 и r_1, r_3 не различить никаким словом: поведение на любое продолжение совпадает.

Проверить вручную бесконечно много слов нельзя.

Нужен алгоритм, который находит все различимые пары за конечное число шагов.



Минимизация

Совершенство достигается не тогда, когда уже нечего прибавить, но когда уже ничего нельзя отнять.

— Антуан де Сент-Экзюпери

Таблица различимостей

Алгоритм Мура заполняет таблицу всех пар состояний:

1. Завести клетки для всех неупорядоченных пар $p \neq q$.
2. Пометить пары, где ровно одно состояние принимающее: их разводит пустое продолжение.
3. Итерация: если для пары (p, q) и символа a пара $(\delta(p, a), \delta(q, a))$ уже помечена — пометить (p, q) .
4. Повторять, пока таблица меняется.
5. Непомеченные пары — эквивалентные состояния: склеить их.

Различимость распространяется назад по дугам: если продолжение разводит образы, разводит и предшественников.

Пример: минимизация четырёх состояний

Для автомата $r_0, \dots, r_3$ сначала помечаются пары с ровно одним принимающим состоянием: $(r_0, r_1), (r_0, r_3), (r_1, r_2), (r_2, r_3)$.

Пара	по 0	по 1	итог
(r_0, r_2)	(r_2, r_2)	(r_1, r_3)	неразличимы
(r_1, r_3)	(r_1, r_3)	(r_0, r_2)	неразличимы

Остальные четыре пары помечены на первом шаге и дальше не участвуют.

Пример

Склейка $r_0 = r_2$ и $r_1 = r_3$ даёт двухсостоятельный автомат чётности.

Единственность минимального ДКА

Теорема 1 (Единственность)

Каждый регулярный язык имеет единственный минимальный ДКА с точностью до изоморфизма — переименования состояний.

Доказательство

Докажем построением изоморфизма.

Сначала лемма: в минимальном ДКА любые два состояния различимы и каждое достижимо — иначе склейка или удаление дали бы автомат меньше.

Пусть M_1, M_2 — два минимальных ДКА. Сопоставим состояниям, в которые ведёт слово x в M_1 и в M_2 , друг друга.

Единственность минимального ДКА [2]

Корректность: если x и y ведут в одно состояние M_1 , они неразличимы, поэтому и в M_2 ведут в одно состояние — иначе M_2 содержал бы различимые состояния там, где M_1 нет.

Сюръективность — из достижимости, инъективность — из различимости.

Начальные состояния, принимающие множества и переходы согласованы, значит построено соответствие — изоморфизм.

Каноническая форма

Минимальный ДКА — портрет языка, а не удача конструктора.

Два автомата распознают один язык тогда и только тогда, когда их минимальные формы изоморфны.

Проверка эквивалентности — конечная процедура: минимизировать оба и сравнить.

Пример

Оптимизаторы регулярных выражений и инструменты анализа протоколов именно так проверяют эквивалентность: сравнением канонических форм.

Число состояний минимального ДКА — объективная мера сложности языка.

Откуда она берётся — сейчас.



Классы неразличимости

Напрасно пытаться посредством большего делать то, что может быть сделано посредством меньшего.

— Уильям Оккам

Неразличимость по продолжению

Определение 2

Для языка L слова x, y **неразличимы по продолжению**, $x \sim_L y$, если

$$\forall z \in \Sigma^* : \quad xz \in L \iff yz \in L.$$

Пример

Для языка слов, заканчивающихся на 01: продолжение 1 разводит ε и $0 - 1 \notin L$, а $01 \in L$.

Отношение $\sim_L$ — эквивалентность на Σ^* : рефлексивность, симметричность и транзитивность наследуются от равенства ответов.

Это тот же язык классов эквивалентности и фактор-множеств, что строился для отношений в первом семестре.

Правые контексты

Определение 3

Правый контекст слова x относительно L :

$$C_x = \{z \in \Sigma^* \mid xz \in L\}.$$

Пример

Слова неразличимы тогда и только тогда, когда их правые контексты совпадают.

Классы $\sim_L$ — это слова с одним контекстом.

Контекст — всё, что язык собирается спросить о слове в будущем.

Состояние автомата хранит в точности это — и ничего больше.

Классы для языка «01»

Для языка слов, заканчивающихся на 01, контекстов три.

Класс слов	Контекст
слова, кончающиеся на 01	нужен пустой остаток
слова, кончающиеся на 0	нужна единица
остальные слова	нужна пара 01

Пример

Три класса — три состояния автомата q_0, q_1, q_2 из детерминированной лекции.

Пустое слово и 1 лежат в одном классе, 0 и 00 — во втором, 01 — в третьем.

Теорема Майхилла–Нерода

Теорема 2 (Майхилл–Нерод)

Для языка L следующие утверждения эквивалентны:

1. L регулярен.
2. Отношение $\sim_L$ имеет конечное число классов.
3. Состояния минимального ДКА для L — это классы $\sim_L$, а переход по a переводит класс $[x]$ в класс $[xa]$.

Доказательство

Докажем по циклу импликаций.

Регулярность $\Rightarrow$ конечный индекс. Слова, ведущие ДКА в одно состояние, неразличимы, поэтому классов не больше, чем состояний.

Теорема Майхилла–Нерода [2]

Конечный индекс $\Rightarrow$ автомат. По классам строится фактор-автомат: переход $[x] \rightarrow [xa]$ корректен, потому что $x \sim_L y$ влечёт $xa \sim_L ya$.

Принимающие классы — те, что содержат слова языка, и распознаётся ровно L .

Классы $\sim_L$ — это и есть состояния самого экономного автомата.

Индекс отношения — точное число состояний минимального ДКА.

Нерегулярность через классы

Пример

Для $L = \{a^n b^n\}$ рассмотрим слова $a, a^2, a^3, \dots$

Для любых $i < j$ продолжение $z = b^i$ разводит их:

$$a^i b^i \in L, \quad a^j b^i \notin L.$$

Все степени a попарно различимы — классов бесконечно много.

Бесконечный индекс $\tilde{L}$ — и язык $a^n b^n$ не регулярен.

В отличие от накачки, доказательство конструктивно: предъявлено бесконечное множество попарно различных слов.

Два инструмента рядом

Инструмент	Что даёт	Граница
Лемма о накачке	опровержение регулярности	необходимое условие, не достаточное
Теорема Майхилла–Нерода	критерий в обе стороны и минимальный автомат	нужно уметь считать классы

Число состояний минимального ДКА равно числу классов $\sim_L$: мера сложности языка — в самом языке, а не в руках конструктора.

Лекция 8: что мы поняли?

- Состояния эквивалентны, если их не различает ни одно слово: склейка таких пар даёт минимизацию.
- Таблица различимостей находит все различимые пары — алгоритм Мура за $O(n^2 \cdot |\Sigma|)$.
- Теорема Майхилла–Нерода: классы неразличимости слов по продолжению — это состояния минимального ДКА, фактор-автомат по правым контекстам.
- Минимальный ДКА единствен с точностью до изоморфизма — каноническая форма языка.
- Конечность модели делает все вопросы о ней решаемыми: пустота, эквивалентность, минимизация.

Вопросы для самопроверки

1. Почему в минимальном ДКА любые два состояния различимы? Что сломалось бы иначе?
2. Найдите слово-свидетель для пары (r_0, r_1) автомата с четырьмя состояниями и объясните, почему для пары (r_0, r_2) свидетеля нет.
3. Опишите классы $\sim_L$ для языка слов с чётным числом единиц.
4. Докажите через Майхилла–Нерода нерегулярность языка палиндромов над $\{a, b\}$.

Чтение к следующей паре

- m23 — «Минимизация ДКА», «Теорема Майхилла–Нерода».
- Флеш-опросник — в начале лекции 9.
- Контрольная 2 (графы, автоматы и регулярные языки) — на этой неделе, на отдельной паре.
- Теорминимум 1 «Графы и автоматы» — на следующей неделе.